


Probabilités et Statistiques

Licence 2 Mathématiques – Semestre 1 – M.BARRY

Année de transition entre maquettes



8 séances de probabilités + 2 séances d'introduction à la statistique

Année universitaire 2026–2027



Ce support couvre : rappels de dénombrement, conditionnement et indépendance, variables aléatoires discrètes et à densité, convergence et théorèmes limites (loi des grands nombres, théorème central limite), statistique descriptive, et une introduction à l'estimation.

Table des matières

Avant-propos	3
1 Modélisation et dénombrement	4
1.1 Expériences aléatoires, univers, événements	4
1.2 Probabilité	4
1.3 Rappels de dénombrement	5
2 Conditionnement et indépendance	8
2.1 Probabilités conditionnelles	8
2.2 Indépendance	9
3 V.a. discrètes : loi et espérance	11
3.1 Loi d'une variable aléatoire discrète	11
3.2 Espérance	11
4 V.a. discrètes : variance et lois usuelles	13
4.1 Variance et écart-type	13
4.2 Lois discrètes usuelles	13
5 Couples de v.a. discrètes	15
5.1 Loi jointe et lois marginales	15
5.2 Indépendance de variables aléatoires	15
5.3 Covariance et corrélation	15
5.4 Espérance conditionnelle	16
5.5 Somme de variables aléatoires indépendantes	17
6 Variables à densité	19
6.1 Densité de probabilité	19
6.2 Fonction de répartition	19
6.3 Espérance et variance	20
6.4 Lois continues usuelles	21
7 Concentration et loi des grands nombres	23
7.1 Inégalités de concentration	23
7.2 Convergence en probabilité	23
7.3 Loi des grands nombres	23
8 Théorème central limite	25
8.1 Fonction caractéristique : un outil pour l'étude des sommes indépendantes	25
8.2 Applications	27
9 Statistique descriptive	28
9.1 Vocabulaire	28
9.2 Représentations graphiques	28
9.3 Indicateurs statistiques	28
10 Estimation et tests	30
10.1 Modèle statistique	30
10.2 Estimateurs	30
10.3 Intervalle de confiance pour une moyenne	30
10.4 Notion de test d'hypothèse	31

Pour aller plus loin	32
-----------------------------	-----------

Avant-propos

Ce cours s'inscrit dans une année de transition entre deux maquettes de formation. Les étudiants qui suivent ce cours en L2 n'auront, sur l'ensemble de leur cursus, que deux enseignements de probabilités et statistiques (celui-ci, puis un cours de probabilités avancées en L3), alors qu'à terme la formation en comportera trois (probabilités finies et dénombrement en L1, probabilités et introduction aux statistiques en L2, probabilités avancées et théorie de la mesure en L3).

Ce support est donc volontairement dense et condensé : il couvre en **8 séances** les bases du calcul des probabilités (rappels, conditionnement, indépendance, variables aléatoires discrètes et à densité, convergence et théorèmes limites), puis en **2 séances** une introduction à la statistique descriptive et à l'estimation.

Par souci de temps, les aspects les plus techniques de la théorie de la mesure (tribus, mesurabilité) ne sont pas abordés : ils seront traités rigoureusement en L3. On travaillera donc, comme c'est l'usage à ce niveau, avec des univers Ω munis de la tribu de tous les événements $\mathcal{F} = \mathcal{P}(\Omega)$ dans le cas discret, et on admettra l'existence des objets nécessaires (tribu borélienne, mesures à densité) dans le cas continu. Certaines démonstrations, moins essentielles à ce niveau, sont admises ou laissées en remarque.

1 Modélisation probabiliste et dénombrement

Séance 1

1.1 Expériences aléatoires, univers, événements

On appelle **expérience aléatoire** une expérience dont on ne peut pas prédire l'issue avec certitude (lancer de dé, tirage dans une urne, durée de vie d'un composant, etc.).

Définition 1.1 – Univers, événements

L'ensemble Ω de tous les résultats possibles d'une expérience aléatoire est appelé **univers** (ou **espace des états**). Un **événement** est un sous-ensemble $A \subset \Omega$. On note $\mathcal{F}$ l'ensemble des événements considérés ; lorsque Ω est fini ou dénombrable, on prend $\mathcal{F} = \mathcal{P}(\Omega)$ (toutes les parties de Ω).

- L'événement **certain** est Ω ; l'événement **impossible** est $\emptyset$.
- L'événement contraire de A est $A^c = \Omega \setminus A$.
- $A \cap B$: A et B ; $A \cup B$: A ou B (non exclusif).
- A et B sont **incompatibles** si $A \cap B = \emptyset$.

Exemple 1.1. Lancer d'un dé à six faces : $\Omega = \{1, 2, 3, 4, 5, 6\}$. L'événement "le résultat est pair" est $A = \{2, 4, 6\}$.

1.2 Probabilité

Définition 1.2 – Probabilité

Une **probabilité** $\mathbb{P}$ sur $(\Omega, \mathcal{F})$ est une application $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ telle que :

1. $\mathbb{P}(\emptyset) = 0$, $\mathbb{P}(\Omega) = 1$;
2. (σ -additivité) pour toute famille au plus dénombrable $(A_i)_{i \in I}$ d'événements deux à deux disjoints,

$$\mathbb{P}\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mathbb{P}(A_i).$$

Le triplet $(\Omega, \mathcal{F}, \mathbb{P})$ est appelé **espace probabilisé**.

Modélisation

On peut interpréter $\mathbb{P}(A)$ de trois façons usuelles : comme une *proportion* (approche classique de Laplace, cas équiprobable), comme une *fréquence limite* lorsqu'on répète l'expérience un grand nombre de fois (approche fréquentiste), ou comme un *degré de croyance* actualisable par la formule de Bayes (approche bayésienne).

Proposition 1 (Propriétés élémentaires)

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé et $A, B \in \mathcal{F}$.

1. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$;
2. si $A \subset B$, alors $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ et $\mathbb{P}(A) \leq \mathbb{P}(B)$;
3. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.

Démonstration. 1. On applique la σ -additivité à A et A^c , disjoints, d'union Ω . 2. On écrit $B = A \sqcup (B \setminus A)$ et on additive. 3. On décompose $A \cup B = A \sqcup (B \setminus A \cap B)$ puis on utilise le point 2. ■

Proposition 2 (Formule d'inclusion-exclusion, ou formule de Poincaré)

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé et $A_1, \dots, A_n \in \mathcal{F}$. Alors

$$\mathbb{P}(A_1 \cup \dots \cup A_n) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}).$$

En particulier, pour $n = 2$ on retrouve le point 3 de la Proposition 1, et pour $n = 3$,

$$\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) + \mathbb{P}(A \cap B \cap C).$$

Démonstration. Par récurrence sur n . Le cas $n = 1$ est trivial, et $n = 2$ est exactement le point 3 de la Proposition 1. Supposons la formule vraie à un rang $n \geq 2$, et montrons-la au rang $n + 1$. Notons $E = A_1 \cup \dots \cup A_n$. D'après le point 3 de la Proposition 1,

$$\mathbb{P}(A_1 \cup \dots \cup A_n \cup A_{n+1}) = \mathbb{P}(E \cup A_{n+1}) = \mathbb{P}(E) + \mathbb{P}(A_{n+1}) - \mathbb{P}(E \cap A_{n+1}).$$

Le terme $\mathbb{P}(E)$ est donné par la formule à l'ordre n (hypothèse de récurrence). Par distributivité de l'intersection sur l'union,

$$E \cap A_{n+1} = (A_1 \cap A_{n+1}) \cup \dots \cup (A_n \cap A_{n+1}),$$

si bien qu'on peut appliquer l'hypothèse de récurrence à cette union de n événements $B_i := A_i \cap A_{n+1}$, ce qui donne $\mathbb{P}(E \cap A_{n+1})$ comme une somme alternée d'intersections de $A_{i_1}, \dots, A_{i_k}, A_{n+1}$. En reportant ces trois termes dans l'égalité ci-dessus et en regroupant soigneusement les indices (les k -uplets d'indices dont le plus grand terme est $\leq n$ d'une part, et ceux dont le plus grand terme vaut $n + 1$ d'autre part), on retrouve exactement la formule annoncée au rang $n + 1$. Les détails de ce réarrangement, purement calculatoires, sont omis ici. ■

Définition 1.3 – Probabilité uniforme

Lorsque Ω est fini, on dit que $\mathbb{P}$ est la **probabilité uniforme** si $\mathbb{P}(\{\omega\}) = 1/\text{card}(\Omega)$ pour tout ω . Dans ce cas, pour tout $A \subset \Omega$,

$$\mathbb{P}(A) = \frac{\text{card}(A)}{\text{card}(\Omega)} = \frac{\text{nombre de cas favorables}}{\text{nombre de cas possibles}}.$$

Remarque

Le choix de Ω et de $\mathbb{P}$ n'est jamais unique : il dépend de ce que l'on souhaite modéliser. Par exemple, pour la somme des faces de deux dés équilibrés, prendre $\Omega = \{2, \dots, 12\}$ muni de la probabilité uniforme est *faux* (les valeurs ne sont pas équiprobables !) ; il faut prendre $\Omega = \{1, \dots, 6\}^2$.

1.3 Rappels de dénombrement

Pour calculer des probabilités uniformes, on a besoin de dénombrer des ensembles. Ces formules ont normalement déjà été vues ; on se contente ici d'un rappel rapide.

Définition 1.4 – Permutations, arrangements, combinaisons

Soit $n \in \mathbb{N}^*$ et $0 \leq k \leq n$.

- Le nombre de **permutations** d'un ensemble à n éléments est $n! = n(n-1) \cdots 1$.

- Le nombre d'**arrangements** de k objets parmi n (tirages ordonnés sans remise) est

$$A_n^k = \frac{n!}{(n-k)!}.$$

- Le nombre de **combinaisons** de k objets parmi n (tirages non ordonnés sans remise), appelé **coefficient binomial**, est

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

Remarque

La formule du binôme de Newton donne $(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$; en particulier $\sum_{k=0}^n \binom{n}{k} = 2^n$. Enfin, pour des tirages *avec* remise et *ordonnés* de k objets parmi n , il y a n^k possibilités.

Application 1.1. On lance deux dés équilibrés distinguables. Calculer $\mathbb{P}$ (la somme fait 7) et $\mathbb{P}$ (la somme fait 12).

Application 1.2. Un jeu de 32 cartes est distribué à 4 joueurs (8 cartes chacun). Combien y a-t-il de répartitions possibles ? Quelle est la probabilité qu'un joueur donné ait les quatre as ?

Application 1.3. Huit nouveaux professeurs sont envoyés dans 4 écoles.

1. Combien d'affectations sont possibles ?
2. Combien d'affectations sont possibles si chaque école doit recevoir exactement 2 professeurs ?

Application 1.4 (Application de la formule de Poincaré). Dans une classe de 30 étudiants, 15 aiment les mathématiques, 12 aiment la physique, 14 aiment l'informatique, 6 aiment à la fois les mathématiques et la physique, 7 aiment à la fois les mathématiques et l'informatique, 5 aiment à la fois la physique et l'informatique, et 3 aiment les trois matières. On choisit un étudiant au hasard. Quelle est la probabilité qu'il aime au moins l'une des trois matières ? Qu'il n'en aime aucune ?

Feuille de TD 1 : Mme Vanessa / M. Barry

Exercice 1.1. On lance deux dés équilibrés.

Question 1. Décrire l'univers Ω associé à cette expérience.

Question 2. Calculer la probabilité d'obtenir une somme égale à 7.

Question 3. Quelle est la probabilité d'obtenir au moins un 6 ?

Exercice 1.2 (Caractéristiques d'une population). La population d'un pays est constituée à 60% de femmes, à 20% d'enfants (filles ou garçons), et à 30% de personnes qui portent des lunettes.

Question 1. Est-il possible que, dans le pays, une femme adulte porte des lunettes ?

Question 2. On apprend par ailleurs que 15% des habitants du pays sont des femmes qui portent des lunettes. Quelle proportion de la population sont des hommes qui ne portent pas de lunettes ?

Question 3. On apprend maintenant que 8% des habitants sont des enfants sans lunettes, et que 12% des habitants sont des enfants garçons.

Vérifier qu'au moins trois quarts des habitants du pays est une femme, ou un enfant, ou une personne à lunettes.

Exercice 1.3 (Une inégalité d'union). Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé, et $A_1, \dots, A_n$ des événements.

Question 1. Démontrer que, si les événements (A_i) recouvrent l'univers, alors la probabilité d'au moins l'un d'entre eux est supérieure ou égale à $1/n$. Autrement dit, démontrer que

$$\bigcup_{i=1}^n A_i = \Omega \implies \exists i \in \{1, \dots, n\}, \quad \mathbb{P}(A_i) \geq \frac{1}{n}.$$

Question 2. Démontrer que

$$\bigcap_{i=1}^n A_i = \emptyset \implies \exists i \in \{1, \dots, n\}, \quad \mathbb{P}(A_i) \leq \frac{n-1}{n}.$$

Exercice 1.4 (Continuité monotone croissante). Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilité. Soit $(A_n)_{n \geq 1}$ une suite d'événements croissante au sens de l'inclusion, c'est-à-dire pour $n \geq 1$, on a :

$$A_n \subset A_{n+1},$$

On pose $A = \bigcup_{n=1}^{+\infty} A_n = \lim_{n \rightarrow +\infty} A_n$.

Démontrer que : $\mathbb{P}(A) = \lim_{n \rightarrow +\infty} \mathbb{P}(A_n)$

2 Probabilités conditionnelles et indépendance

Séance 2

2.1 Probabilités conditionnelles

Définition 2.1 – Probabilité conditionnelle

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé et $B \in \mathcal{F}$ tel que $\mathbb{P}(B) > 0$. La probabilité de A sachant B est

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Remarque

On peut interpréter $\mathbb{P}(A | B)$ comme la proportion de A parmi les issues où B est réalisé. On a alors $\mathbb{P}(A \cap B) = \mathbb{P}(A | B) \mathbb{P}(B)$.

Proposition 3 (Formule des probabilités composées)

Soient $A_1, \dots, A_n \in \mathcal{F}$ des événements tels que $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) \neq 0$. Alors

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdot \mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}).$$

Démonstration. L'idée est celle d'un **télescopage** : en notant que chaque probabilité conditionnelle est bien définie (car $0 < \mathbb{P}(A_1 \cap \dots \cap A_{n-1}) \leq \mathbb{P}(A_1 \cap \dots \cap A_i)$ pour tout $i \leq n-1$), on a

$$\begin{aligned} & \mathbb{P}(A_1) \cdot \underbrace{\mathbb{P}(A_2 | A_1)}_{= \mathbb{P}(A_1 \cap A_2) / \mathbb{P}(A_1)} \cdot \mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}), \\ & \underbrace{\hspace{10em}}_{= \mathbb{P}(A_1 \cap A_2)} \end{aligned}$$

où chaque facteur, en simplifiant avec le précédent, fait apparaître l'intersection d'un événement de plus, jusqu'à obtenir $\mathbb{P}(A_1 \cap \dots \cap A_n)$ après le dernier facteur. Une récurrence sur n permet de rendre cet argument rigoureux. ■

Exemple 2.1 (Tirages successifs sans remise). Une urne contient 10 boules noires et 1 boule rouge. On tire successivement et sans remise 5 boules dans l'urne. Quelle est la probabilité d'avoir tiré 5 boules noires ?

Pour $n \in \{1, \dots, 5\}$, notons A_n l'événement "après n tirages, n boules noires ont été tirées" ; on cherche donc $\mathbb{P}(A_5)$. On a $\mathbb{P}(A_1) = 10/11$, et pour tout $n \in \{1, \dots, 4\}$, sachant A_n (donc sachant que les n premiers tirages ont donné des boules noires), il reste $11-n$ boules dans l'urne, dont $10-n$ noires, si bien que $\mathbb{P}(A_{n+1} | A_n) = (10-n)/(11-n)$. Comme $A_5 \subset A_4 \subset \dots \subset A_1$, la formule des probabilités composées donne

$$\mathbb{P}(A_5) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdot \mathbb{P}(A_3 | A_2) \cdot \mathbb{P}(A_4 | A_3) \cdot \mathbb{P}(A_5 | A_4) = \frac{10}{11} \cdot \frac{9}{10} \cdot \frac{8}{9} \cdot \frac{7}{8} \cdot \frac{6}{7} = \frac{6}{11}.$$

Définition 2.2 – Système complet d'événements

Une famille $(A_i)_{i \in I}$ au plus dénombrable est un **système complet d'événements** (ou une **partition**) si les A_i sont deux à deux disjoints et $\bigcup_i A_i = \Omega$.

Proposition 4 (Formule des probabilités totales)

Soit $(A_i)_{i \in I}$ un système complet d'événements de probabilités non nulles. Pour tout événement B ,

$$\mathbb{P}(B) = \sum_{i \in I} \mathbb{P}(A_i) \mathbb{P}(B | A_i).$$

Cette formule se visualise avec un **arbre de probabilités** : à chaque branche est associée une probabilité conditionnelle, et la probabilité d'un chemin est le produit des probabilités portées par ses branches.

Proposition 5 (Formule de Bayes)

Soit $(A_i)_{i \in I}$ un système complet d'événements de probabilités non nulles et B un événement de probabilité non nulle. Pour tout $i_0 \in I$,

$$\mathbb{P}(A_{i_0} | B) = \frac{\mathbb{P}(A_{i_0}) \mathbb{P}(B | A_{i_0})}{\sum_{i \in I} \mathbb{P}(A_i) \mathbb{P}(B | A_i)}.$$

Démonstration. Il suffit d'écrire $\mathbb{P}(A_{i_0} | B) = \mathbb{P}(A_{i_0} \cap B) / \mathbb{P}(B)$, puis d'utiliser $\mathbb{P}(A_{i_0} \cap B) = \mathbb{P}(A_{i_0}) \mathbb{P}(B | A_{i_0})$ et la formule des probabilités totales au dénominateur. ■

Exemple 2.2 (Test de dépistage). *Un test de dépistage a une sensibilité de 98% (probabilité d'être positif sachant que l'on est malade) et une spécificité de 97% (probabilité d'être négatif sachant que l'on est sain). On suppose que la maladie touche 1 personne sur 1000. Un individu est testé positif : quelle est la probabilité qu'il soit réellement malade ? Notons M "être malade" et T "test positif". On a $\mathbb{P}(M) = 0,001$, $\mathbb{P}(T | M) = 0,98$, $\mathbb{P}(T | M^c) = 0,03$. Par la formule de Bayes,*

$$\mathbb{P}(M | T) = \frac{0,001 \times 0,98}{0,001 \times 0,98 + 0,999 \times 0,03} \approx 3,2\%.$$

Ce résultat, contre-intuitif, illustre l'importance de prendre en compte la rareté de la maladie (la prévalence) et pas seulement la qualité du test.

2.2 Indépendance

Définition 2.3 – Indépendance de deux événements

Deux événements A et B sont **indépendants** si

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

Remarque

Si $\mathbb{P}(B) > 0$, A et B sont indépendants si et seulement si $\mathbb{P}(A | B) = \mathbb{P}(A)$: savoir que B est réalisé ne change pas la probabilité de A . Si A et B sont indépendants, alors (A, B^c) , (A^c, B) et (A^c, B^c) le sont aussi.

Définition 2.4 – Indépendance mutuelle

Une famille finie d'événements $A_1, \dots, A_n$ est **mutuellement indépendante** si, pour

tout sous-ensemble d'indices $\{i_1, \dots, i_k\} \subset \{1, \dots, n\}$,

$$\mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) = \mathbb{P}(A_{i_1}) \dots \mathbb{P}(A_{i_k}).$$

Remarque

Attention : une indépendance deux à deux n'implique pas l'indépendance mutuelle !
 Exemple : on lance deux fois une pièce équilibrée et on pose A = “pile au 1er lancer”, B = “face au 2e lancer”, C = “les deux lancers donnent le même résultat”. On vérifie que A, B, C sont indépendants deux à deux mais $\mathbb{P}(A \cap B \cap C) = 0 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 1/8$.

Application 2.1 (Le problème de Monty Hall). *Un jeu télévisé comporte trois portes A, B, C . Derrière l'une d'elles se trouve un cadeau, rien derrière les deux autres. Vous choisissez une porte au hasard, disons A . Le présentateur, qui sait où est le cadeau, ouvre alors l'une des deux autres portes, derrière laquelle il n'y a rien. On vous propose de changer ou non de porte. Montrer qu'il est plus avantageux de changer de porte (on pourra introduire les événements G_A, G_B, G_C et O_B, O_C et utiliser la formule de Bayes).*

Application 2.2. *Une urne contient 4 boules blanches et 6 boules noires. On tire successivement, sans remise, deux boules. Quelle est la probabilité que la deuxième boule soit blanche sachant que la première est noire ? Les deux tirages sont-ils indépendants ?*

Application 2.3. *Soient A, B, C trois événements mutuellement indépendants. Montrer que C est indépendant de $A \cup B$.*

3 Variables aléatoires discrètes : loi et espérance

Séance 3

3.1 Loi d'une variable aléatoire discrète

Définition 3.1 – Variable aléatoire discrète

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. Une **variable aléatoire discrète** est une application $X : \Omega \rightarrow E$, où E est fini ou dénombrable (le plus souvent $E \subset \mathbb{R}$). Pour $A \subset E$, on note

$$\mathbb{P}(X \in A) := \mathbb{P}(\{\omega \in \Omega : X(\omega) \in A\}).$$

La **loi** de X est la donnée des probabilités $p_x = \mathbb{P}(X = x)$ pour $x \in E$; on a $p_x \geq 0$ et $\sum_{x \in E} p_x = 1$.

Exemple 3.1. On lance deux dés équilibrés indépendants et on note X leur somme. Alors X est une variable aléatoire discrète à valeurs dans $\{2, \dots, 12\}$, de loi $\mathbb{P}(X = 7) = 6/36$, $\mathbb{P}(X = 2) = 1/36$, etc.

Définition 3.2 – Fonction de répartition

La **fonction de répartition** de X est la fonction $F_X : \mathbb{R} \rightarrow [0, 1]$ définie par $F_X(x) = \mathbb{P}(X \leq x)$. Elle est croissante, continue à droite, de limite 0 en $-\infty$ et 1 en $+\infty$. Pour une variable discrète, F_X est en escalier (constante par morceaux, avec des sauts de hauteur $\mathbb{P}(X = x)$ aux points x du support).

3.2 Espérance

Définition 3.3 – Espérance

Soit X une variable aléatoire discrète réelle à valeurs dans $E \subset \mathbb{R}$. Si $\sum_{x \in E} |x| \mathbb{P}(X = x) < \infty$, on dit que X admet une espérance (ou est **intégrable**), et on pose

$$\mathbb{E}[X] = \sum_{x \in E} x \mathbb{P}(X = x).$$

L'espérance s'interprète comme la **moyenne pondérée** des valeurs prises par X , les poids étant les probabilités : c'est l'analogue théorique de la moyenne empirique que l'on retrouvera en statistique.

Théorème (de transfert)

Soit X une variable aléatoire discrète à valeurs dans E et $g : \mathbb{R} \rightarrow \mathbb{R}$ une fonction. Si $\sum_{x \in E} |g(x)| \mathbb{P}(X = x) < \infty$, alors $g(X)$ est intégrable et

$$\mathbb{E}[g(X)] = \sum_{x \in E} g(x) \mathbb{P}(X = x).$$

Ce théorème est fondamental : il permet de calculer l'espérance d'une fonction de X (par exemple X^2) directement à partir de la loi de X , **sans** avoir à déterminer la loi de $g(X)$.

Proposition 6 (Linéarité et positivité)

Soient X, Y deux variables aléatoires discrètes intégrables et $\alpha, \beta \in \mathbb{R}$. Alors $\alpha X + \beta Y$ est intégrable et

$$\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y].$$

De plus, si $X \geq 0$ presque sûrement, $\mathbb{E}[X] \geq 0$; et si $X \leq Y$ presque sûrement, $\mathbb{E}[X] \leq \mathbb{E}[Y]$.

Application 3.1. On lance un dé équilibré à six faces ; soit X le résultat obtenu. Calculer $\mathbb{E}[X]$ et $\mathbb{E}[X^2]$.

Application 3.2. Une urne contient 5 boules numérotées de 1 à 5. On tire une boule au hasard, on note X son numéro, on la remet dans l'urne avec une boule supplémentaire portant le même numéro, puis on tire une nouvelle boule dont le numéro est noté Y . Calculer $\mathbb{E}[X]$. (On admettra que $\mathbb{E}[Y] = \mathbb{E}[X]$; le vérifier est un bon exercice de révision sur les probabilités totales.)

Application 3.3. Neuf chevaux, quatre blancs et cinq noirs, entrent un par un sur la piste d'un cirque, dans un ordre aléatoire. Soit X le nombre de chevaux blancs précédant le premier cheval noir. Donner la loi de X et calculer $\mathbb{E}[X]$.

4 Variables aléatoires discrètes : variance et lois usuelles

Séance 4

4.1 Variance et écart-type

Définition 4.1 – Variance, écart-type

Soit X une variable aléatoire discrète telle que X^2 soit intégrable (on dit que X est **de carré intégrable**). La **variance** de X est

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2,$$

et l'**écart-type** est $\sigma_X = \sqrt{\text{Var}(X)}$.

Remarque

$\text{Var}(X)$ mesure la dispersion des valeurs de X autour de sa moyenne : plus $\text{Var}(X)$ est petite, plus X est concentrée autour de $\mathbb{E}[X]$. On a toujours $\text{Var}(X) \geq 0$, avec égalité si et seulement si X est presque sûrement constante. Pour $a, b \in \mathbb{R}$:

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

4.2 Lois discrètes usuelles

Définition 4.2 – Loi de Bernoulli $\mathcal{B}(p)$

$X \sim \mathcal{B}(p)$, $p \in [0, 1]$, si $\mathbb{P}(X = 1) = p$ et $\mathbb{P}(X = 0) = 1 - p$. On a $\mathbb{E}[X] = p$ et $\text{Var}(X) = p(1 - p)$.

Modélisation

Modélise une expérience à deux issues (succès/échec, pile/face, ...).

Définition 4.3 – Loi binomiale $\mathcal{B}(n, p)$

$X \sim \mathcal{B}(n, p)$, $n \in \mathbb{N}^*$, $p \in [0, 1]$, si pour tout $k \in \{0, \dots, n\}$,

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

On a $\mathbb{E}[X] = np$ et $\text{Var}(X) = np(1 - p)$.

Modélisation

Nombre de succès obtenus en répétant n fois, de manière indépendante, une expérience de Bernoulli de paramètre p . Si $X_1, \dots, X_n$ sont i.i.d. de loi $\mathcal{B}(p)$, alors $\sum_{i=1}^n X_i \sim \mathcal{B}(n, p)$.

Définition 4.4 – Loi géométrique $\mathcal{G}(p)$

$X \sim \mathcal{G}(p)$, $p \in (0, 1]$, si pour tout $n \in \mathbb{N}^*$, $\mathbb{P}(X = n) = (1 - p)^{n-1}p$. On a $\mathbb{E}[X] = 1/p$ et $\text{Var}(X) = (1 - p)/p^2$.

Modélisation

Nombre d'expériences de Bernoulli indépendantes, de paramètre p , nécessaires pour obtenir le premier succès. Loi "sans mémoire" : $\mathbb{P}(X > n + k \mid X > n) = \mathbb{P}(X > k)$.

Définition 4.5 – Loi de Poisson $\mathcal{P}(\lambda)$

$X \sim \mathcal{P}(\lambda)$, $\lambda > 0$, si pour tout $k \in \mathbb{N}$, $\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$. On a $\mathbb{E}[X] = \text{Var}(X) = \lambda$.

Modélisation

Modélise le nombre d'occurrences d'un événement rare sur une période donnée (nombre de clients, d'accidents, de mails reçus, ...). C'est la loi limite d'une loi binomiale $\mathcal{B}(n, \lambda/n)$ quand $n \rightarrow \infty$ (approximation des événements rares).

Loi	Espérance	Variance
Bernoulli $\mathcal{B}(p)$	p	$p(1 - p)$
Binomiale $\mathcal{B}(n, p)$	np	$np(1 - p)$
Géométrique $\mathcal{G}(p)$	$1/p$	$(1 - p)/p^2$
Poisson $\mathcal{P}(\lambda)$	λ	λ

Application 4.1. Soit N fixé et X prenant les valeurs $-N, 0, N$ avec probabilité $1/3$ chacune. Calculer $\mathbb{E}[X]$, $\text{Var}(X)$ et l'écart-type de X .

Application 4.2. On lance n fois une pièce non nécessairement équilibrée, de probabilité $p \in (0, 1)$ de tomber sur pile. Soit X le nombre de piles obtenus. Identifier la loi de X , calculer $\mathbb{E}[X]$ et $\text{Var}(X)$.

Application 4.3. Un standard téléphonique reçoit en moyenne 3 appels par minute, modélisés par une loi de Poisson. Calculer la probabilité de ne recevoir aucun appel en une minute, puis la probabilité de recevoir au moins un appel.

Application 4.4. Un étudiant s'ennuie en cours et regarde tomber les feuilles d'un arbre. On admet que le nombre de feuilles tombées à la fin du cours suit une loi de Poisson de paramètre $\lambda > 0$. Calculer $\mathbb{E}[X]$ et $\text{Var}(X)$.

5 Couples de variables aléatoires discrètes

Séance 5

5.1 Loi jointe et lois marginales

Définition 5.1 – Couple de variables aléatoires, loi jointe

Soient X, Y deux variables aléatoires discrètes définies sur le même espace probabilisé, à valeurs respectivement dans I et J . La **loi jointe** du couple (X, Y) est la donnée des probabilités

$$p_{i,j} = \mathbb{P}(X = x_i, Y = y_j), \quad (x_i, y_j) \in I \times J.$$

Les **lois marginales** de X et Y s'obtiennent en sommant :

$$\mathbb{P}(X = x_i) = \sum_{j \in J} p_{i,j}, \quad \mathbb{P}(Y = y_j) = \sum_{i \in I} p_{i,j}.$$

Remarque

La loi jointe détermine les lois marginales, mais **pas l'inverse** : deux couples peuvent avoir les mêmes lois marginales sans avoir la même loi jointe (et donc ne pas se comporter de la même façon).

5.2 Indépendance de variables aléatoires

Définition 5.2 – Indépendance

X et Y sont **indépendantes** si pour tout $(x, y) \in I \times J$,

$$\mathbb{P}(X = x, Y = y) = \mathbb{P}(X = x) \mathbb{P}(Y = y).$$

Proposition 7

Si X et Y sont indépendantes et $g, h : \mathbb{R} \rightarrow \mathbb{R}$, alors $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)] \mathbb{E}[h(Y)]$ (dès que ces quantités existent). En particulier, $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y]$.

5.3 Covariance et corrélation

Définition 5.3 – Covariance

Pour X, Y de carré intégrable, la **covariance** de X et Y est

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Le **coefficient de corrélation linéaire** est $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$.

Proposition 8

1. Si X, Y sont indépendantes, alors $\text{Cov}(X, Y) = 0$ (la réciproque est fausse !).
2. $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$; si X, Y sont indépendantes, $\text{Var}(X +$

$$Y) = \text{Var}(X) + \text{Var}(Y).$$

3. Plus généralement, si $X_1, \dots, X_n$ sont indépendantes, $\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$.

Ce dernier point sera la clé de voûte de la loi des grands nombres (Séance 7).

5.4 Espérance conditionnelle

Définition 5.4 – Loi conditionnelle et espérance conditionnelle

Soient X, Y deux variables aléatoires discrètes, X à valeurs dans I . Pour $y \in J$ tel que $\mathbb{P}(Y = y) > 0$, la **loi conditionnelle** de X sachant $\{Y = y\}$ est donnée par

$$\mathbb{P}(X = x \mid Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}, \quad x \in I,$$

et l'**espérance conditionnelle** de X sachant $\{Y = y\}$ est

$$\mathbb{E}[X \mid Y = y] = \sum_{x \in I} x \mathbb{P}(X = x \mid Y = y).$$

On définit alors $\mathbb{E}[X \mid Y]$ comme la variable aléatoire $\varphi(Y)$, où $\varphi(y) = \mathbb{E}[X \mid Y = y]$: c'est donc une fonction (aléatoire) de Y seule.

Proposition 9 (Formule de l'espérance totale)

Pour toutes variables aléatoires discrètes X, Y (avec X intégrable),

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid Y]] = \sum_{y \in J} \mathbb{P}(Y = y) \mathbb{E}[X \mid Y = y].$$

Démonstration. En développant le membre de droite et en intervertissant les deux sommes (licite, les termes étant en nombre fini ou la série étant absolument convergente puisque X est intégrable) :

$$\sum_{y \in J} \mathbb{P}(Y = y) \mathbb{E}[X \mid Y = y] = \sum_{y \in J} \mathbb{P}(Y = y) \sum_{x \in I} x \mathbb{P}(X = x \mid Y = y) = \sum_{y \in J} \sum_{x \in I} x \mathbb{P}(X = x, Y = y).$$

En regroupant par x :

$$\sum_{x \in I} x \sum_{y \in J} \mathbb{P}(X = x, Y = y) = \sum_{x \in I} x \mathbb{P}(X = x) = \mathbb{E}[X],$$

la dernière égalité étant la formule des probabilités totales appliquée à la partition $(\{Y = y\})_{y \in J}$. ■

Exemple 5.1 (Somme de piles conditionnée par un dé). *On lance un dé équilibré à six faces, dont le résultat est noté N (donc N suit la loi uniforme sur $\{1, \dots, 6\}$). Sachant $N = n$, on lance ensuite n fois une pièce équilibrée indépendante, et Y désigne le nombre de piles obtenus parmi ces n lancers. Ainsi, conditionnellement à $\{N = n\}$, Y suit la loi $\mathcal{B}(n, 1/2)$, d'où $\mathbb{E}[Y \mid N = n] = n/2$. Par la formule de l'espérance totale,*

$$\mathbb{E}[Y] = \sum_{n=1}^6 \mathbb{P}(N = n) \mathbb{E}[Y \mid N = n] = \sum_{n=1}^6 \frac{1}{6} \cdot \frac{n}{2} = \frac{1}{12} \sum_{n=1}^6 n = \frac{1}{12} \cdot \frac{6 \cdot 7}{2} = \frac{21}{12} = \frac{7}{4}.$$

On retrouve d'ailleurs directement ce résultat en écrivant $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y \mid N]] = \mathbb{E}[N/2] = \mathbb{E}[N]/2 = (7/2)/2 = 7/4$, puisque $\mathbb{E}[N] = 7/2$ pour une loi uniforme sur $\{1, \dots, 6\}$.

5.5 Somme de variables aléatoires indépendantes

Proposition 10 (Formule de convolution)

Soient X, Y deux variables aléatoires discrètes indépendantes, à valeurs dans $\mathbb{Z}$ (ou dans $\mathbb{N}$). Alors, pour tout k ,

$$\mathbb{P}(X + Y = k) = \sum_i \mathbb{P}(X = i) \mathbb{P}(Y = k - i).$$

Démonstration. Les événements $(\{X = i, Y = k - i\})_i$, pour i décrivant les valeurs prises par X , forment une partition de l'événement $\{X + Y = k\}$ (à chaque issue de $\{X + Y = k\}$ correspond une unique valeur i de X). Par σ -additivité puis indépendance de X et Y ,

$$\mathbb{P}(X + Y = k) = \sum_i \mathbb{P}(X = i, Y = k - i) = \sum_i \mathbb{P}(X = i) \mathbb{P}(Y = k - i).$$

■

Exemple 5.2 (Somme de Bernoulli i.i.d. : preuve par récurrence). Soient $X_1, \dots, X_n, \dots$ des variables i.i.d. de loi $\mathcal{B}(p)$, et $S_n = X_1 + \dots + X_n$. Montrons par récurrence sur $n \geq 1$ que $S_n \sim \mathcal{B}(n, p)$.

Initialisation. $S_1 = X_1 \sim \mathcal{B}(p) = \mathcal{B}(1, p)$.

Hérédité. Supposons $S_n \sim \mathcal{B}(n, p)$. Comme S_n et X_{n+1} sont indépendantes (la première ne dépend que de $X_1, \dots, X_n$) et $X_{n+1} \in \{0, 1\}$, la formule de convolution donne, pour $k \in \{0, \dots, n+1\}$,

$$\mathbb{P}(S_{n+1} = k) = \mathbb{P}(S_n = k) \mathbb{P}(X_{n+1} = 0) + \mathbb{P}(S_n = k - 1) \mathbb{P}(X_{n+1} = 1).$$

En utilisant l'hypothèse de récurrence $\mathbb{P}(S_n = j) = \binom{n}{j} p^j (1-p)^{n-j}$:

$$\begin{aligned} \mathbb{P}(S_{n+1} = k) &= \binom{n}{k} p^k (1-p)^{n-k} (1-p) + \binom{n}{k-1} p^{k-1} (1-p)^{n-k+1} p \\ &= \left[\binom{n}{k} + \binom{n}{k-1} \right] p^k (1-p)^{n+1-k}. \end{aligned}$$

Par la formule de Pascal, $\binom{n}{k} + \binom{n}{k-1} = \binom{n+1}{k}$, d'où $\mathbb{P}(S_{n+1} = k) = \binom{n+1}{k} p^k (1-p)^{n+1-k}$, c'est-à-dire $S_{n+1} \sim \mathcal{B}(n+1, p)$. La propriété est donc vraie pour tout $n \geq 1$.

Exemple 5.3 (Somme de Poisson indépendantes : preuve par convolution directe). Soient $X_1 \sim \mathcal{P}(\lambda_1)$ et $X_2 \sim \mathcal{P}(\lambda_2)$ indépendantes, $\lambda_1, \lambda_2 > 0$. Montrons que $X_1 + X_2 \sim \mathcal{P}(\lambda_1 + \lambda_2)$. Pour $k \in \mathbb{N}$, la formule de convolution donne

$$\mathbb{P}(X_1 + X_2 = k) = \sum_{i=0}^k \mathbb{P}(X_1 = i) \mathbb{P}(X_2 = k - i) = \sum_{i=0}^k e^{-\lambda_1} \frac{\lambda_1^i}{i!} \cdot e^{-\lambda_2} \frac{\lambda_2^{k-i}}{(k-i)!}.$$

En mettant $e^{-(\lambda_1 + \lambda_2)}$ et $\frac{1}{k!}$ en facteur :

$$\mathbb{P}(X_1 + X_2 = k) = \frac{e^{-(\lambda_1 + \lambda_2)}}{k!} \sum_{i=0}^k \binom{k}{i} \lambda_1^i \lambda_2^{k-i} = \frac{e^{-(\lambda_1 + \lambda_2)}}{k!} (\lambda_1 + \lambda_2)^k,$$

la dernière égalité étant la formule du binôme de Newton. On reconnaît la loi $\mathcal{P}(\lambda_1 + \lambda_2)$.

Ce résultat se généralise par récurrence à une somme finie de variables de Poisson indépendantes.

Application 5.1. On considère le couple (X, Y) de loi jointe donnée par $\mathbb{P}(X = k, Y = \ell) = A \binom{n-1}{i-1} \binom{n-1}{j-1}$ pour $(i, j) \in \{1, \dots, n\}^2$, où A est une constante.

1. Déterminer A .
2. Les variables X et Y sont-elles indépendantes ?

Application 5.2. On lance n fois une pièce, X désignant le nombre de piles et Y le nombre de faces obtenus. Calculer $\text{Cov}(X, Y)$ et le coefficient de corrélation linéaire de X et Y . Indication : $X + Y = n$.

Application 5.3. Soient X_1, X_2 deux variables indépendantes de loi de Poisson de paramètres respectifs $\lambda_1, \lambda_2 > 0$, et $N = X_1 + X_2$ (on a vu que $N \sim \mathcal{P}(\lambda_1 + \lambda_2)$).

1. Montrer que, pour $n \geq 0$ fixé, la loi conditionnelle de X_1 sachant $\{N = n\}$ est la loi binomiale $\mathcal{B}(n, \frac{\lambda_1}{\lambda_1 + \lambda_2})$. Indication : écrire $\mathbb{P}(X_1 = k \mid N = n) = \frac{\mathbb{P}(X_1 = k, X_2 = n - k)}{\mathbb{P}(N = n)}$ pour $0 \leq k \leq n$, et utiliser l'indépendance de X_1, X_2 .
2. En déduire $\mathbb{E}[X_1 \mid N = n]$, puis retrouver $\mathbb{E}[X_1] = \lambda_1$ à l'aide de la formule de l'espérance totale appliquée à la partition $(\{N = n\})_{n \geq 0}$.

6 Variables aléatoires à densité

Séance 6

Certaines quantités aléatoires (taille, durée de vie, mesure physique) ne prennent pas des valeurs isolées mais varient de façon continue : leur loi ne se décrit plus par des probabilités ponctuelles $\mathbb{P}(X = x)$ (qui valent toutes 0), mais par une **densité**.

6.1 Densité de probabilité

Définition 6.1 – Densité de probabilité

On appelle **densité de probabilité** toute fonction $f : \mathbb{R} \rightarrow \mathbb{R}$, continue par morceaux, telle que :

1. $f(x) \geq 0$ pour tout x (sauf éventuellement en un nombre fini de points) ;
2. $\int_{-\infty}^{+\infty} f(x) dx = 1$.

Définition 6.2 – Variable aléatoire à densité

Une variable aléatoire réelle X est dite **à densité** (ou **continue**), de densité f_X , si pour tout intervalle $I \subset \mathbb{R}$,

$$\mathbb{P}(X \in I) = \int_I f_X(t) dt.$$

Remarque

Pour une variable à densité, $\mathbb{P}(X = x) = 0$ pour tout $x \in \mathbb{R}$: il ne faut donc jamais confondre « $\mathbb{P}(X = x) = 0$ » avec « l'événement $\{X = x\}$ est impossible ». On en déduit aussi que

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b) = \int_a^b f_X(t) dt.$$

6.2 Fonction de répartition

Définition 6.3 – Fonction de répartition d'une v.a. à densité

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(t) dt.$$

Proposition 11 (Propriétés de la fonction de répartition)

Soit X une variable aléatoire à densité f_X , de fonction de répartition F_X . Alors :

1. F_X est **croissante** sur $\mathbb{R}$, avec $\lim_{x \rightarrow -\infty} F_X(x) = 0$ et $\lim_{x \rightarrow +\infty} F_X(x) = 1$;
2. F_X est **continue** sur $\mathbb{R}$ tout entier (contrairement au cas discret, où F_X présente des sauts aux points du support) ;
3. F_X est dérivable en tout point où f_X est continue, et $F'_X(x) = f_X(x)$ en ces points ;
4. pour tous $a \leq b$ dans $\mathbb{R}$,

$$\mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b) = F_X(b) - F_X(a)$$

(les bornes n'ont pas d'importance ici, puisque $\mathbb{P}(X = a) = \mathbb{P}(X = b) = 0$) ;

5. réciproquement, si F est une fonction *continue*, croissante, $\mathcal{C}^1$ par morceaux, de limite 0 en $-\infty$ et 1 en $+\infty$, alors F est la fonction de répartition d'une variable à densité, dont une densité est donnée par $f = F'$ là où F est dérivable.

Remarque

Le point 5 est très utile en pratique : il permet de **retrouver la densité à partir de la fonction de répartition**, simplement en dérivant F . C'est l'objet du second exemple ci-dessous.

Exemple 6.1 (De la densité vers la fonction de répartition). Soit X une variable aléatoire de densité $f_X(x) = 3x^2 \mathbf{1}_{[0,1]}(x)$.

1. Vérifions qu'il s'agit bien d'une densité : $f_X \geq 0$, et

$$\int_{-\infty}^{+\infty} f_X(x) dx = \int_0^1 3x^2 dx = [x^3]_0^1 = 1.$$

2. Calculons F_X . Pour $x < 0$, $F_X(x) = 0$. Pour $x > 1$, $F_X(x) = 1$. Pour $0 \leq x \leq 1$,

$$F_X(x) = \int_{-\infty}^x f_X(t) dt = \int_0^x 3t^2 dt = [t^3]_0^x = x^3.$$

Ainsi

$$F_X(x) = \begin{cases} 0 & x < 0 \\ x^3 & 0 \leq x \leq 1 \\ 1 & x > 1. \end{cases}$$

On vérifie bien que F_X est continue, croissante, et que $F'_X(x) = 3x^2 = f_X(x)$ sur $(0, 1)$.

3. Utilisons F_X pour calculer une probabilité. Par le point 4 de la Proposition 11,

$$\mathbb{P}(0,5 < X \leq 0,8) = F_X(0,8) - F_X(0,5) = 0,8^3 - 0,5^3 = 0,512 - 0,125 = 0,387.$$

Exemple 6.2 (De la fonction de répartition vers la densité). On considère la fonction $F(x) =$

$$\begin{cases} 0 & x \leq 0 \\ \sqrt{x} & 0 < x \leq 1 \\ 1 & x > 1. \end{cases}$$

1. Vérifions que F est bien une fonction de répartition. F est continue en 0 ($\sqrt{0} = 0$) et en 1 ($\sqrt{1} = 1$), croissante sur $[0, 1]$ (car $x \mapsto \sqrt{x}$ l'est), de limite 0 en $-\infty$ et 1 en $+\infty$: par le point 5 de la Proposition 11, F est bien la fonction de répartition d'une variable à densité X .
2. Calculons sa densité en dérivant F sur $(0, 1)$:

$$f_X(x) = F'(x) = \frac{1}{2\sqrt{x}}, \quad 0 < x < 1,$$

et $f_X(x) = 0$ ailleurs. On vérifie que $\int_0^1 \frac{1}{2\sqrt{x}} dx = [\sqrt{x}]_0^1 = 1$, ce qui confirme que f_X est bien une densité de probabilité.

3. Calculons une probabilité directement à partir de F , sans repasser par une intégrale de f_X :

$$\mathbb{P}(X > 1/4) = 1 - \mathbb{P}(X \leq 1/4) = 1 - F(1/4) = 1 - \sqrt{1/4} = 1 - \frac{1}{2} = \frac{1}{2}.$$

6.3 Espérance et variance

Théorème (Espérance et transfert, cas continu)

Soit X une variable à densité f_X . Si $\int_{-\infty}^{+\infty} |x| f_X(x) dx < \infty$,

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx.$$

Plus généralement, pour $g : \mathbb{R} \rightarrow \mathbb{R}$ continue par morceaux, dès que l'intégrale a un sens,

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx.$$

Comme dans le cas discret, on définit alors $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$, avec $\mathbb{E}[X^2] = \int x^2 f_X(x) dx$. Les propriétés de linéarité, positivité et croissance de l'espérance, ainsi que les formules de la variance et de la covariance, restent valables telles quelles.

6.4 Lois continues usuelles

Définition 6.4 – Loi uniforme $\mathcal{U}([a, b])$

$X \sim \mathcal{U}([a, b])$ si $f_X(x) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$. On a $\mathbb{E}[X] = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Modélisation

Modélise une valeur “choisie au hasard” dans un intervalle, sans privilégier aucune zone (position d’une aiguille, heure d’arrivée dans un intervalle donné, etc.).

Définition 6.5 – Loi exponentielle $\mathcal{E}(\lambda)$

$X \sim \mathcal{E}(\lambda)$, $\lambda > 0$, si $f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x \geq 0\}}$. On a $\mathbb{E}[X] = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$, et

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-\lambda x} & x \geq 0. \end{cases}$$

Modélisation

Modélise des temps d’attente ou des durées de vie “sans mémoire” ou “sans vieillissement” (durée de vie d’un composant électronique, temps entre deux appels, etc.).

Définition 6.6 – Loi normale (ou gaussienne) $\mathcal{N}(m, \sigma^2)$

$X \sim \mathcal{N}(m, \sigma^2)$, $m \in \mathbb{R}$, $\sigma > 0$, si

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right).$$

On a $\mathbb{E}[X] = m$ et $\text{Var}(X) = \sigma^2$. Lorsque $m = 0$, $\sigma = 1$, on parle de loi **normale centrée réduite** $\mathcal{N}(0, 1)$.

Modélisation

La loi normale est omniprésente en sciences et en statistique, en particulier parce qu'elle apparaît comme loi limite de sommes de nombreuses variables indépendantes (théorème central limite, Séance 8). Il n'existe pas d'expression explicite de sa fonction de répartition ; on utilise des tables ou des logiciels.

Loi	Densité $f(x)$	Espérance	Variance
$\mathcal{U}([a, b])$	$\frac{1}{b-a} \mathbf{1}_{[a,b]}(x)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
$\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x} \mathbf{1}_{\{x \geq 0\}}$	$1/\lambda$	$1/\lambda^2$
$\mathcal{N}(m, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-(x-m)^2/2\sigma^2}$	m	σ^2

Application 6.1. Soit $X \sim \mathcal{U}([0, 1])$. Calculer $\mathbb{P}(X \leq 1/3)$, $\mathbb{E}[X]$, $\text{Var}(X)$, puis la loi de $Y = 2X + 1$ (on déterminera sa densité).

Application 6.2. La durée de vie T (en années) d'un composant électronique suit une loi exponentielle de paramètre $\lambda = 0,1$. Calculer la probabilité que le composant fonctionne encore après 5 ans, puis après 15 ans sachant qu'il fonctionne encore après 10 ans (on retrouvera l'absence de mémoire : $\mathbb{P}(T > t + s \mid T > t) = \mathbb{P}(T > s)$).

Application 6.3. Soit X une variable aléatoire de densité $f(x) = c(1 - x^2)$ sur $[-1, 1]$ et 0 ailleurs. Déterminer c , calculer $\mathbb{E}[X]$ et $\text{Var}(X)$.

7 Inégalités de concentration et loi des grands nombres

Séance 7

On s'intéresse maintenant au comportement des moyennes empiriques lorsque l'on répète un grand nombre de fois une expérience aléatoire : c'est le socle théorique qui justifiera, en particulier, les méthodes statistiques des deux dernières séances.

7.1 Inégalités de concentration

Proposition 12 (Inégalité de Markov)

Soit X une variable aléatoire positive et $a > 0$. Alors

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

Démonstration. On a $X \geq a \mathbf{1}_{\{X \geq a\}}$ (car sur $\{X \geq a\}$ le membre de droite vaut $a \leq X$, et sinon il vaut $0 \leq X$). En prenant l'espérance et en utilisant la croissance, $\mathbb{E}[X] \geq a\mathbb{P}(X \geq a)$. ■

Proposition 13 (Inégalité de Bienaymé–Tchebychev)

Soit X une variable aléatoire d'espérance μ et de variance σ^2 . Pour tout $\varepsilon > 0$,

$$\mathbb{P}(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

Démonstration. On applique l'inégalité de Markov à la variable positive $(X - \mu)^2$ avec $a = \varepsilon^2$: $\mathbb{P}((X - \mu)^2 \geq \varepsilon^2) \leq \mathbb{E}[(X - \mu)^2]/\varepsilon^2 = \sigma^2/\varepsilon^2$, et on conclut car $\{(X - \mu)^2 \geq \varepsilon^2\} = \{|X - \mu| \geq \varepsilon\}$. ■

Ces inégalités permettent de **borner**, sans connaître précisément la loi de X , la probabilité que X s'éloigne beaucoup de sa moyenne : c'est une première forme de “concentration”.

7.2 Convergence en probabilité

Définition 7.1 – Convergence en probabilité

Une suite de variables aléatoires $(X_n)_{n \geq 1}$ **converge en probabilité** vers une variable X si, pour tout $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

7.3 Loi des grands nombres

Théorème 7.1 (Loi (faible) des grands nombres). Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires indépendantes et de même loi (i.i.d.), d'espérance μ et de variance σ^2 finie. Soit $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ la **moyenne empirique**. Alors $\bar{X}_n$ converge en probabilité vers μ : pour tout $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0.$$

Démonstration. Par indépendance, $\text{Var}(\bar{X}_n) = \frac{1}{n^2} \text{Var}(\sum_{i=1}^n X_i) = \frac{\sigma^2}{n}$, et $\mathbb{E}[\bar{X}_n] = \mu$.

L'inégalité de Tchebychev donne alors

$$\mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

■

Remarque

Il existe une version plus forte de ce résultat, la **loi forte des grands nombres**, qui affirme que $\bar{X}_n \rightarrow \mu$ *presque sûrement*, c'est-à-dire avec probabilité 1. C'est ce résultat qui justifie rigoureusement l'interprétation fréquentiste des probabilités : la proportion de succès dans une répétition d'expériences converge vers la probabilité théorique de succès.

Application 7.1. Soient $X_1, \dots, X_n$ des variables i.i.d. d'espérance μ et de variance σ^2 . Montrer que $\mathbb{E}[\bar{X}_n] = \mu$ et $\text{Var}(\bar{X}_n) = \sigma^2/n$.

Application 7.2. Une pièce a une probabilité p inconnue de tomber sur pile. On la lance $n = 1000$ fois et on observe 520 piles. Utiliser l'inégalité de Tchebychev pour majorer la probabilité que la fréquence empirique de piles diffère de p de plus de 0,05, en fonction de $p(1-p) \leq 1/4$.

Application 7.3. Soit X une variable aléatoire positive d'espérance 10. Majorer $\mathbb{P}(X \geq 50)$ à l'aide de l'inégalité de Markov.

8 Théorème central limite

Séance 8

La loi des grands nombres affirme que $\bar{X}_n$ se stabilise autour de μ , mais ne dit rien sur la *vitesse* ni la *forme* de cette convergence. C'est l'objet du théorème central limite (TCL), l'un des résultats les plus importants des probabilités.

Théorème 8.1 (Théorème central limite). Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires i.i.d., d'espérance μ et de variance $\sigma^2 > 0$. Soit $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Alors, pour tout $t \in \mathbb{R}$,

$$\mathbb{P} \left(\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \leq t \right) \xrightarrow{n \rightarrow \infty} \Phi(t) := \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-s^2/2} ds,$$


c'est-à-dire que $\sqrt{n}(\bar{X}_n - \mu)/\sigma$ converge en loi vers une variable de loi normale centrée réduite $\mathcal{N}(0, 1)$.

Remarque

De façon plus intuitive, pour n grand, la loi de $\bar{X}_n$ est approximativement

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

La démonstration rigoureuse du TCL repose sur les **fonctions caractéristiques**, présentées dans la sous-section suivante.



distribution approchée de $\bar{X}_n$ (loi normale)

8.1 Fonction caractéristique : un outil pour l'étude des sommes indépendantes

Définition 8.1 – Fonction caractéristique

Soit X une variable aléatoire réelle (discrète ou à densité). On appelle **fonction caractéristique** de X la fonction $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ définie par

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \mathbb{E}[\cos(tX)] + i \mathbb{E}[\sin(tX)], \quad t \in \mathbb{R}.$$

Cette espérance est toujours bien définie, quelle que soit la loi de X , et $|\varphi_X(t)| \leq 1$ pour tout t , car $|e^{itX}| = 1$.

Remarque

Si X est discrète à valeurs dans D , $\varphi_X(t) = \sum_{x \in D} e^{itx} \mathbb{P}(X = x)$; si X admet une densité f_X , $\varphi_X(t) = \int_{\mathbb{R}} e^{itx} f_X(x) dx$. La fonction caractéristique est donc, pour une variable réelle quelconque, l'analogue de la fonction génératrice $G_X(t) = \mathbb{E}[t^X]$ des variables discrètes à valeurs entières : dans les deux cas, on encode toute la loi de X dans une seule fonction, ce qui permet d'en tirer facilement moments et comportement des sommes.

Proposition 14 (Propriétés fondamentales)

Soit X une variable aléatoire réelle, de fonction caractéristique φ_X .

1. **(Caractérisation de la loi)** φ_X détermine entièrement la loi de X : si deux variables X et Y vérifient $\varphi_X = \varphi_Y$, alors X et Y ont la même loi.
2. **(Lien avec les moments)** Si X admet un moment d'ordre $k \in \mathbb{N}^*$, alors φ_X est k fois dérivable en 0, et $\varphi_X^{(k)}(0) = i^k \mathbb{E}[X^k]$. En particulier,

$$\mathbb{E}[X] = \frac{\varphi_X'(0)}{i}, \quad \text{Var}(X) = -\varphi_X''(0) + (\varphi_X'(0))^2.$$

3. **(Somme de variables indépendantes)** Si X et Y sont indépendantes, alors

$$\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t), \quad t \in \mathbb{R}.$$

Plus généralement, si $X_1, \dots, X_n$ sont indépendantes, la fonction caractéristique de leur somme $S_n = X_1 + \dots + X_n$ est le *produit* des fonctions caractéristiques : $\varphi_{S_n} = \varphi_{X_1} \cdots \varphi_{X_n}$.

Remarque

Le point 3 explique pourquoi la fonction caractéristique est un outil si puissant pour étudier les sommes de variables indépendantes : une opération a priori compliquée sur les lois (la *convolution*, qui donne la loi d'une somme) devient une simple **multiplication** de fonctions caractéristiques. C'est précisément ce principe qui permet de démontrer rigoureusement le théorème central limite : on montre que la fonction caractéristique de $\sqrt{n}(\bar{X}_n - \mu)/\sigma$ converge, pour tout $t \in \mathbb{R}$, vers $e^{-t^2/2}$ – qui est exactement la fonction caractéristique de la loi $\mathcal{N}(0, 1)$ – et le point 1 permet alors de conclure à la convergence en loi. Les détails techniques de cette démonstration dépassent le cadre de ce cours, mais l'idée est là : *transformer une somme en produit, et un produit en limite simple à identifier*.

Exemple 8.2. On admet que la fonction caractéristique d'une loi $\mathcal{N}(0, 1)$ est $\varphi(t) = e^{-t^2/2}$. Si $X_1, \dots, X_n$ sont indépendantes, toutes de loi $\mathcal{N}(0, 1)$, alors par la propriété 3,

$$\varphi_{X_1 + \dots + X_n}(t) = (e^{-t^2/2})^n = e^{-nt^2/2},$$

qui est la fonction caractéristique de la loi $\mathcal{N}(0, n)$. On retrouve ainsi, de façon exacte (et sans passage à la limite), que la somme de n gaussiennes centrées réduites indépendantes suit une loi $\mathcal{N}(0, n)$.

Application 8.1. Soit $X \sim \mathcal{B}(p)$ une variable de Bernoulli. Calculer $\varphi_X(t) = \mathbb{E}[e^{itX}]$, puis retrouver $\mathbb{E}[X] = p$ à l'aide de la formule $\mathbb{E}[X] = \varphi_X'(0)/i$.

Application 8.2. Soient $X_1, \dots, X_n$ i.i.d. de loi $\mathcal{B}(p)$ et $S_n = \sum_{i=1}^n X_i$. Exprimer φ_{S_n} en fonction de φ_{X_1} , et en déduire l'expression de φ_{S_n} . On admettra que la fonction

caractéristique de la loi $\mathcal{B}(n, p)$ est $t \mapsto (1 - p + pe^{it})^n$: que peut-on en conclure sur la loi de S_n , et pourquoi ?

Application 8.3. Soient $X \sim \mathcal{P}(\lambda_1)$ et $Y \sim \mathcal{P}(\lambda_2)$ indépendantes, de fonctions caractéristiques respectives $\varphi_X(t) = e^{\lambda_1(e^{it}-1)}$ et $\varphi_Y(t) = e^{\lambda_2(e^{it}-1)}$. Calculer φ_{X+Y} et en déduire la loi de $X + Y$ (comparer avec l'exercice analogue de la Séance 5, traité sans fonction caractéristique).

8.2 Applications

Intervalles de confiance. Le TCL permet de construire un intervalle aléatoire contenant μ avec une probabilité approximativement fixée. Pour $a > 0$, en posant $I_{n,a} = [\bar{X}_n - \frac{a\sigma}{\sqrt{n}}, \bar{X}_n + \frac{a\sigma}{\sqrt{n}}]$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(\mu \in I_{n,a}) = \Phi(a) - \Phi(-a).$$

Pour un niveau de confiance de 95%, on prend $a \approx 1,96$.

Approximation de lois discrètes. Si $S_n \sim \mathcal{B}(n, p)$, on peut écrire $S_n = \sum_{i=1}^n X_i$ avec X_i i.i.d. de loi $\mathcal{B}(p)$. Le TCL donne, pour n grand,

$$S_n \approx \mathcal{N}(np, np(1-p)).$$

Application 8.4. Soient $X_1, \dots, X_n, \dots$ des variables i.i.d. de loi de Poisson de paramètre 1.

1. Rappeler $\mathbb{E}[X_1]$ et $\text{Var}(X_1)$.
2. En utilisant le TCL, donner un équivalent, quand $n \rightarrow \infty$, du comportement de $\mathbb{P}(\sum_{i=1}^n X_i \leq n)$.

Application 8.5. On sonde $n = 400$ électeurs et 208 déclarent vouloir voter pour un candidat A. On modélise le sondage par une somme de 400 variables de Bernoulli indépendantes de paramètre p (proportion réelle d'électeurs pour A dans la population). Donner un intervalle de confiance approché à 95% pour p .

Application 8.6. Un dé équilibré est lancé $n = 180$ fois. Soit S_n la somme des résultats. Donner une valeur approchée de $\mathbb{P}(S_n \geq 650)$ à l'aide du TCL (on rappelle que pour un dé équilibré, $\mathbb{E}[X] = 3,5$ et $\text{Var}(X) = 35/12$).

9 Statistique descriptive

Séance 9

On passe maintenant du cadre théorique des probabilités à l'analyse de données observées. La **statistique** a pour objet de recueillir, traiter et analyser des données issues de phénomènes aléatoires.

9.1 Vocabulaire

- Les données sont des mesures faites sur des **individus** (ou unités statistiques) issus d'une **population**.
- On s'intéresse à une (ou plusieurs) **variable(s)** ou caractère(s) des individus.
- L'ensemble des individus observés constitue l'**échantillon**, noté $x_1, \dots, x_n$. On suppose que ces données sont les réalisations de n variables aléatoires $X_1, \dots, X_n$ i.i.d. de même loi qu'une variable X .
- La **statistique descriptive** vise à résumer l'information contenue dans les données de façon synthétique (graphiques, tableaux, indicateurs numériques), sans faire d'hypothèse probabiliste forte. La **statistique inférentielle** (Séance 10) va plus loin : elle propose des modèles probabilistes et cherche à faire des prévisions.

9.2 Représentations graphiques

- Pour une variable **qualitative** ou discrète à peu de modalités : **diagramme en bâtons** (hauteur proportionnelle à la fréquence) ou **diagramme sectoriel** (camembert).
- Pour une variable **continue** (ou discrète à beaucoup de valeurs) : on regroupe les observations en **classes** $[a_{j-1}, a_j]$ et on construit un **histogramme**, dont l'aire de chaque rectangle est égale à la fréquence de la classe correspondante.
- La **fonction de répartition empirique** $F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{x_i \leq t}$ est une fonction en escalier qui estime $F(t) = \mathbb{P}(X \leq t)$.

9.3 Indicateurs statistiques

Définition 9.1 – Moyenne et variance empiriques

Pour un échantillon $x_1, \dots, x_n$:

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{moyenne empirique}),$$

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}_n^2 \quad (\text{variance empirique}),$$


et l'**écart-type empirique** est $s_n = \sqrt{s_n^2}$.

Définition 9.2 – Médiane et quantiles

Soit $x_1^* \leq \dots \leq x_n^*$ l'échantillon ordonné. La **médiane** est $x_{(n+1)/2}^*$ si n est impair, et $\frac{1}{2}(x_{n/2}^* + x_{n/2+1}^*)$ si n est pair. Plus généralement, le **quantile empirique** d'ordre $p \in (0, 1)$ est, essentiellement, la valeur $x_{[np]+1}^*$ (à une convention près lorsque $np \in \mathbb{N}$). Les quantiles d'ordre $1/4$, $1/2$, $3/4$ sont les **quartiles** ; la médiane est le quantile d'ordre $1/2$.

Remarque

La moyenne et l'écart-type sont sensibles aux **valeurs aberrantes** ; la médiane et l'écart interquartile ($q_{3/4} - q_{1/4}$) sont beaucoup plus robustes. Le **boxplot** (ou “boîte à moustaches”) représente le premier et le troisième quartile (bords de la boîte), la médiane (trait épais), ainsi que les valeurs extrêmes non aberrantes (moustaches).



Application 9.1. Paul a noté pendant 12 jours la température (en °C) au lever du jour :

−3; −4; 0; 1; 5; 5; 2; −1; −5; 2; 6; 7.

Calculer la moyenne, ordonner la série, déterminer la médiane, les trois quartiles et l'étendue.

Application 9.2. Un professeur augmente toutes les notes d'un examen de 10% : une note x devient $y = x + x/10 = 1,1x$. Parmi les affirmations suivantes, lesquelles sont vraies ?

1. La moyenne empirique augmente de 10% et l'écart-type reste inchangé.
2. La moyenne et la variance empiriques augmentent de 10%.
3. La moyenne augmente de 10% et la variance de 21%.
4. La médiane augmente de 10%.

Justifier chaque réponse à l'aide des formules $\overline{ax + b} = a\bar{x} + b$ et $s_{ax+b}^2 = a^2 s_x^2$.

Application 9.3. On dispose d'un échantillon de taille n noté $x_1, \dots, x_n$, de moyenne $\bar{x}_n$. On ajoute une donnée supplémentaire égale à $\bar{x}_n$. Que devient la moyenne de l'échantillon de taille $n + 1$? Et si l'on ajoute une donnée égale à la médiane de l'échantillon initial ?

10 Introduction à l'estimation et aux tests

Séance 10

Remarque

Cette dernière séance est une **introduction rapide**, à traiter si le temps le permet. Il s'agit surtout de donner aux étudiants les idées essentielles de la démarche inférentielle ; les notions seront reprises et approfondies dans un cours ultérieur.

10.1 Modèle statistique

On observe un échantillon $x_1, \dots, x_n$, réalisation de variables aléatoires $X_1, \dots, X_n$ i.i.d. de même loi qu'une variable X , dont on suppose que la loi dépend d'un paramètre inconnu θ (par exemple $\theta = p$ pour une loi de Bernoulli, ou $\theta = (m, \sigma^2)$ pour une loi normale). Le but de l'**estimation** est de proposer, à partir des données, une valeur approchée de θ .

10.2 Estimateurs

Définition 10.1 – Estimateur

Un **estimateur** de θ est une variable aléatoire $\hat{\theta}_n = g(X_1, \dots, X_n)$, fonction des observations, destinée à approcher θ . Sa réalisation sur les données observées, $g(x_1, \dots, x_n)$, est une **estimation** (un nombre).

Définition 10.2 – Biais, convergence

Un estimateur $\hat{\theta}_n$ est dit **sans biais** si $\mathbb{E}[\hat{\theta}_n] = \theta$ pour tout θ . Il est dit **convergent** si $\hat{\theta}_n$ converge en probabilité vers θ quand $n \rightarrow \infty$.

Exemple 10.1 (Moyenne et variance empiriques). Si $X_1, \dots, X_n$ sont i.i.d. d'espérance μ et de variance σ^2 , la moyenne empirique $\bar{X}_n = \frac{1}{n} \sum X_i$ est un estimateur sans biais et convergent de μ (c'est exactement la loi des grands nombres, Séance 7). Pour la variance, on peut montrer que l'estimateur

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

(variance empirique corrigée) est sans biais pour σ^2 , alors que la variance empirique "naïve" $\frac{1}{n} \sum (X_i - \bar{X}_n)^2$ est légèrement biaisée (mais convergente).

10.3 Intervalle de confiance pour une moyenne

Le TCL (Séance 8) permet de construire, pour n grand, un intervalle de confiance approché pour $\mu = \mathbb{E}[X]$:

$$IC_{95\%} = \left[\bar{X}_n - 1,96 \frac{S_n}{\sqrt{n}}, \bar{X}_n + 1,96 \frac{S_n}{\sqrt{n}} \right],$$

où S_n est l'écart-type empirique corrigé. Un tel intervalle contient, en moyenne, θ dans 95% des cas si on répétait l'expérience un grand nombre de fois – ce n'est **pas** la probabilité que μ appartienne à cet intervalle précis, qui n'est plus aléatoire une fois les données observées.

10.4 Notion de test d'hypothèse

Définition 10.3 – Test d'hypothèse (principe)

Un **test statistique** permet de trancher, à partir des données, entre une **hypothèse nulle** H_0 (ce que l'on suppose *a priori*) et une **hypothèse alternative** H_1 . On se fixe un **niveau** (ou risque de première espèce) $\alpha \in (0, 1)$ (souvent 5%), qui majore la probabilité de rejeter H_0 à tort. On construit une statistique de test dont la loi est connue sous H_0 , et on rejette H_0 si la valeur observée est “trop éloignée” de ce que prévoit H_0 .

Exemple 10.2 (Test sur une proportion). *On veut savoir si une pièce est équilibrée ($H_0 : p = 1/2$) à partir de n lancers. Sous H_0 , le nombre de piles S_n suit (approximativement, via le TCL) une loi $\mathcal{N}(n/2, n/4)$. On rejette H_0 au niveau 5% si*

$$\left| \frac{S_n - n/2}{\sqrt{n}/2} \right| > 1,96.$$

Application 10.1. *On mesure 25 pièces produites par une machine ; la moyenne empirique des longueurs est $\bar{x} = 50,2$ mm et l'écart-type empirique corrigé $s = 0,5$ mm. Construire un intervalle de confiance à 95% pour la longueur moyenne réelle des pièces.*

Application 10.2. *On sonde 200 personnes et 112 déclarent préférer un produit A à un produit B. Peut-on rejeter, au niveau 5%, l'hypothèse H_0 : “les deux produits sont préférés dans les mêmes proportions” ?*

Application 10.3 (Réflexion). *Expliquer, en une phrase, la différence entre un estimateur sans biais et un estimateur convergent. Un estimateur peut-il être convergent sans être sans biais ? Sans biais sans être convergent ?*

Pour aller plus loin

Ce cours condensé laisse volontairement de côté plusieurs aspects qui seront développés ultérieurement :

- le cadre rigoureux de la théorie de la mesure (tribus, mesurabilité, intégrale de Lebesgue), qui permet de traiter de façon unifiée variables discrètes et continues (cours de L3) ;
- la fonction génératrice des variables aléatoires discrètes, analogue de la fonction caractéristique (Séance 8) restreint aux variables entières ;
- la démonstration complète du théorème central limite à partir des fonctions caractéristiques (nous en avons seulement présenté le principe, Séance 8) ;
- les vecteurs aléatoires, les couples de variables à densité, et les lois multivariées ;
- la théorie de l'estimation (maximum de vraisemblance, propriétés asymptotiques des estimateurs) et des tests statistiques usuels (test de Student, du χ^2 , ...).

Références utilisées pour la préparation de ce cours :

- D. Giraudo, *Probabilités et Statistiques S4*, Université de Strasbourg, polycopié de cours 2023–2024.
- Y. Offret, *Cours de Probabilités*, Université Bourgogne Europe, IMB, 2025–2026.